




**Asignatura: Recurse EXTRACCIÓN
CONOCIMIENTOS EN BASE DE DATOS**

**Tema: Actividad de Evaluación – Unidad I.
Planeación del Proyecto de Análisis de Datos.**

Proyecto: Análisis de riesgo crediticio de clientes



Alumno: Alexander Domínguez Zárate

Matrícula: 23301324



Contenido

Nombre del proyecto.....	2
Descripción del proyecto	2
Planteamiento del problema	3
Pregunta principal de análisis	3
Objetivo general	3
Objetivos específicos	4
Alcance y limitaciones	5
1. Alcance	5
2. Limitaciones	5
Descripción del dataset.....	6
1.1 Identificación.....	6
1.2 Tipos de variables	6
1.3 Posibles variables objetivo	6
Análisis comparativo	7
Herramientas propuestas	9
Metodología	9
Definición preliminar del análisis supervisado	10
1.1 Regresión	10
1.2 Clasificación	10
Resultados esperados	11
Cronograma	12
Ruta de aprendizaje.....	12
Productos finales esperados.....	14
Referencias bibliográficas	15

Nombre del proyecto

Análisis de riesgo crediticio de clientes.

Descripción del proyecto

El proyecto realiza un análisis integral del dataset **South German Credit**: 1,000 casos de crédito y 21 variables financieras, crediticias, laborales, personales y habitacionales (historial crediticio, cuenta corriente, monto y duración, ahorros, antigüedad laboral, propiedades, edad, vivienda, otros créditos). La variable principal es `credit_risk`, con categorías `good` y `bad`.

Se desarrollará como un ejercicio de **Extracción de Conocimiento en Bases de Datos (KDD)**: análisis exploratorio, preparación y transformación, almacenamiento estructurado, aprendizaje supervisado y no supervisado. Además de clasificar el riesgo, se explorará un problema de regresión y la identificación de perfiles de clientes mediante clustering y reducción de dimensionalidad. Los resultados se comunicarán en un dashboard.

Planteamiento del problema

Evaluar el riesgo crediticio exige analizar múltiples características de solicitantes y créditos; una revisión manual dificulta identificar patrones y una sola variable rara vez explica el comportamiento de un crédito. Las preguntas que motivan el análisis son:

- ¿Qué características difieren entre créditos *good* y *bad*?
- ¿Qué variables sirven para explicar o predecir el riesgo?
- ¿Es posible construir modelos que clasifiquen el riesgo?
- ¿Qué características permiten estimar el monto de un crédito?
- ¿Existen perfiles de clientes identificables con técnicas no supervisadas?

Este análisis **no** busca establecer causalidad ni crear una regla automática para conceder o rechazar créditos; su propósito es extraer conocimiento del conjunto disponible.

Pregunta principal de análisis

¿Qué patrones presentes en las características financieras, crediticias y personales de los clientes permiten explicar y modelar el comportamiento observado de los créditos en el dataset South German Credit?

Enfoque	Pregunta específica
Clasificación	¿Es posible clasificar un crédito como <i>good</i> o <i>bad</i> con las características disponibles?
Regresión	¿Es posible estimar el monto del crédito a partir de las demás características?
No supervisado	¿Es posible identificar grupos de clientes con perfiles similares?

Objetivo general

Analizar y transformar los datos de South German Credit mediante técnicas de KDD para identificar patrones relacionados con el riesgo crediticio, desarrollar modelos supervisados y no supervisados, y comunicar los resultados mediante visualización.

Ciclo completo:

datos originales → comprensión → exploración → limpieza → transformación → almacenamiento → análisis → modelos → evaluación → conocimiento → visualización.

Objetivos específicos

N.º	Objetivo	Indicadores verificables
1	Examinar y documentar estructura, características y calidad del dataset mediante diccionario de datos y análisis exploratorio.	Diccionario de datos; tipos de variables; estadísticas descriptivas; distribuciones; valores faltantes y atípicos; distribución de credit_risk.
2	Diseñar e implementar la preparación y transformación de datos para obtener un conjunto procesado adecuado para análisis y ML.	Proceso ETL documentado; dataset procesado; codificación de categóricas; tratamiento de numéricas; validación de calidad.
3	Diseñar un Data Warehouse o Data Mart para organizar la información del análisis.	Modelos conceptual y lógico; tablas y relaciones; scripts SQL; carga de datos procesados.
4	Desarrollar y evaluar modelos supervisados: clasificación de riesgo y regresión del monto.	≥1 modelo de clasificación y ≥1 de regresión; métricas; comparación; interpretación de errores y limitaciones.
5	Aplicar aprendizaje no supervisado para identificar grupos de clientes y explorar la estructura multidimensional.	Clustering; evaluación de grupos; reducción de dimensionalidad; visualización; interpretación de perfiles.
6	Construir un dashboard que comunique los principales resultados y patrones.	Dashboard funcional; indicadores; visualizaciones; filtros; storytelling.

Alcance y limitaciones

1. Alcance

- Descarga y revisión del dataset original.
- Documentación de variables.
- Análisis exploratorio.
- Limpieza y transformación.
- Proceso ETL.
- Diseño de Data Warehouse o Data Mart.
- Almacenamiento de datos procesados.
- Análisis supervisado (regresión y clasificación).
- Análisis no supervisado (clustering y reducción de dimensionalidad).
- Evaluación e interpretación de modelos.
- Visualizaciones y dashboard.
- Documentación completa.
- Control de versiones con Git y GitHub.

2. Limitaciones

Antigüedad: créditos de aproximadamente 1973–1975; no representan automáticamente el sistema financiero actual.

Tamaño: 1,000 registros; suficiente para ejercicios de análisis, pero pequeño para representar una población amplia.

Muestreo: los créditos malos están sobrerrepresentados, por lo que la proporción de bad no equivale a una tasa real de incumplimiento.

Variables codificadas: muchas se representan con códigos numéricos; se debe distinguir entre numéricas, categóricas, ordinales y binarias.

Información histórica: no incluye variables de sistemas financieros modernos.

Inferencia: los modelos tienen finalidad académica y analítica, no de aprobación real de créditos.

Descripción del dataset

1.1 Identificación

Característica	Información
Dataset	South German Credit
Fuente	UCI Machine Learning Repository
Registros	1,000
Variables	21 (20 predictoras potenciales)
Objetivo de clasificación	credit_risk
Posible objetivo de regresión	amount
Valores faltantes	No reportados
Tipo	Datos tabulares (riesgo crediticio)

Fuente oficial: <https://archive.ics.uci.edu/dataset/573/south+german+credit>

1.2 Tipos de variables

Tipo	Ejemplos
Cuantitativas	duration, amount, age
Categóricas	status, credit_history, purpose, savings, housing
Ordinales	employment_duration, installment_rate, present_residence, number_credits, job
Binarias	people_liable, telephone, foreign_worker
Objetivo categórica	credit_risk (good, bad)

1.3 Posibles variables objetivo

Regresión: amount, para estudiar si las demás características permiten estimarlo.

Clasificación: credit_risk (good / bad).

No supervisado: sin variable objetivo; se buscan grupos, perfiles, componentes principales y relaciones entre variables.

Análisis comparativo

Característica	IA	Machine Learning	Data Mining	Big Data
Enfoque	Sistemas con capacidades asociadas a la inteligencia	Aprendizaje desde datos	Descubrimiento de patrones	Gestión de grandes volúmenes
Alcance	Muy amplio	Subcampo de IA	Análisis de datos	Infraestructura + análisis
Predicción	Sí	Sí	Puede utilizarla	Puede incorporarla
Clustering	Puede utilizarlo	Sí	Sí	Sí
Requiere grandes datos	No necesariamente	No	No necesariamente	Sí, normalmente
Ejemplo en el proyecto	Sistema inteligente	Clasificador de riesgo	Descubrimiento de patrones	Escenario financiero escalable

Inteligencia Artificial. Campo general que desarrolla sistemas capaces de razonar, percibir, aprender o decidir. *Beneficios:* automatización, reconocimiento de patrones, apoyo a decisiones. *Restricciones:* dependencia de datos, errores, interpretabilidad, sesgos, validación humana. *Herramientas:* Python, R, Java, TensorFlow, PyTorch, Scikit-learn.

Machine Learning. Subcampo de IA que aprende patrones a partir de datos; en el proyecto se usa para regresión, clasificación y clustering. *Beneficios:* predicción, patrones complejos, comparación de algoritmos. *Restricciones:* calidad de datos,

overfitting, selección de variables, evaluación con métricas. *Herramientas*: Python, Scikit-learn, Pandas, NumPy, Matplotlib, Seaborn.

Data Mining. Descubre patrones, relaciones y conocimiento útil en los datos; relevante para identificar patrones de riesgo y segmentar clientes. *Restricciones*: los patrones no implican causalidad y puede haber información espuria. *Técnicas*: clasificación, regresión, clustering, reducción de dimensionalidad, asociación.

Big Data. Manejo de datos con alto volumen, velocidad, variedad, veracidad y valor. El dataset **no** es Big Data por su tamaño, pero estudiarlo ayuda a entender cómo escalarían estas técnicas a millones de clientes. *Herramientas*: Hadoop, Spark, Kafka, Databricks, almacenamiento distribuido.

Herramientas propuestas

Herramienta	Uso en el proyecto
Python	Lenguaje principal: carga, limpieza, transformación, EDA, modelos y visualización
Pandas	Lectura, filtrado, transformación, agrupamiento, limpieza y análisis descriptivo
NumPy	Operaciones numéricas
Matplotlib y Seaborn	Visualizaciones exploratorias
Scikit-learn	Partición de datos, preprocesamiento, regresión, clasificación, clustering, PCA, métricas y validación
PostgreSQL y SQL	Almacenamiento de datos procesados, Data Warehouse/Data Mart, consultas y validación
Git y GitHub	Control de versiones, documentación, reproducibilidad y presentación
Jupyter Notebook	Documentación del proceso exploratorio y experimental
Dashboard	Power BI, Tableau o Streamlit; se decidirá según necesidades e integración con los datos

Metodología

El proyecto toma como referencia el proceso **KDD** (datos → selección → preprocesamiento → transformación → minería de datos → evaluación/interpretación → conocimiento) y se organiza con **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), por su estructura práctica y amplio uso. Sus fases no son estrictamente lineales: se puede volver a etapas previas cuando los resultados lo requieran.

Fase CRISP-DM	Qué se hace	Aplicación al proyecto
1. Comprensión del negocio	Definir problema, objetivos, preguntas, alcance, restricciones y criterios de éxito	Definir el problema de riesgo crediticio, monto y perfiles

Fase CRISP-DM	Qué se hace	Aplicación al proyecto
2. Comprensión de los datos	Estudiar estructura, variables, tipos, distribución, calidad, faltantes, atípicos y relaciones	Diccionario de datos, análisis descriptivo, distribuciones y calidad
3. Preparación	Limpieza, transformación, codificación, normalización, selección de variables y datasets finales	raw → ETL → processed → Data Warehouse / Data Mart
4. Modelado	Regresión (amount), clasificación (credit_risk), clustering y PCA	Modelos supervisados y no supervisados
5. Evaluación	Desempeño, errores, métricas, estabilidad, interpretabilidad y overfitting	Un modelo no se elige solo por su métrica: debe ser coherente y explicable
6. Despliegue	Resultados finales, dashboard, documentación y repositorio reproducible	No implica convertir el modelo en un sistema financiero real

Definición preliminar del análisis supervisado

1.1 Regresión

Objetivo propuesto: **`amount`**, el monto del crédito. Variables candidatas: duration, status, credit_history, savings, employment_duration, installment_rate, age, property, number_credits, entre otras. La selección definitiva se hará tras el análisis exploratorio.

1.2 Clasificación

Objetivo: **`credit\_risk`** (good / bad). Se compararán distintos algoritmos con accuracy, precision, recall, F1-score, matriz de confusión y ROC-AUC cuando sea apropiado. Debido al desbalance de clases, no se evaluará únicamente con accuracy.

Resultados esperados

1. **Características de los datos:** variables, significado, tipos y distribuciones.
2. **Patrones de riesgo:** relaciones entre las características de los clientes y credit_risk.
3. **Modelo de clasificación:** si es posible clasificar créditos como good o bad.
4. **Modelo de regresión:** si las características permiten estimar el monto.
5. **Perfiles de clientes:** posibles agrupamientos mediante técnicas no supervisadas.
6. **Reducción de dimensionalidad:** si pocos componentes capturan una parte importante de la variabilidad.
7. **Visualización:** dashboard con distribución de créditos, características de clientes, comportamiento de riesgo, resultados de modelos y perfiles.

Los resultados serán **hallazgos del dataset estudiado**, no reglas universales sobre el comportamiento crediticio.

Cronograma

Fecha	Actividad	Producto esperado
2 octubre	Documento de planeación	Informe inicial del proyecto
9 octubre	Diccionario de datos, exploración y limpieza inicial	Diccionario + notebook EDA + propuesta DW/Data Mart
16 octubre	ETL, datos procesados, DW/Data Mart y repositorio	Pipeline ETL + dataset procesado + estructura de BD
23 octubre	Modelos de regresión y clasificación	Primeros modelos funcionando
30 octubre	Análisis supervisado	Modelos + métricas + evaluación + optimización + informe
6 noviembre	Clustering y reducción de dimensionalidad	Modelos no supervisados funcionando
13 noviembre	Análisis no supervisado	Modelos + evaluación + interpretación + informe
17 noviembre	Dashboard y storytelling	Dashboard revisado + narrativa preliminar
20 noviembre	Entrega final	Dashboard + repositorio + informe + defensa

Ruta de aprendizaje

El proyecto también es una ruta progresiva de aprendizaje, y cada fase debe producir evidencia en el repositorio:

- Comprender el problema
- Comprender los datos
- Python + Pandas + SQL
- ETL + Data Warehouse
- Análisis exploratorio
- Regresión
- Clasificación
- Evaluación y optimización
- Clustering

- PCA
- Visualización
- Dashboard + storytelling
- Documentación y defensa

El objetivo es poder responder en la defensa preguntas como: ¿por qué elegiste esa variable objetivo y ese modelo?, ¿cómo preparaste y codificaste los datos?, ¿cómo sabes que el modelo funciona y qué métrica usaste?, ¿qué significan un falso positivo y un falso negativo?, ¿puede generalizar?, ¿qué limitaciones tiene el dataset?, ¿qué aportan el clustering y PCA?, ¿cuál es el hallazgo más importante del dashboard? y ¿qué **no** puedes concluir con estos datos? El repositorio funcionará como **bitácora técnica** del proceso.

Productos finales esperados

```
south-german-credit/
├─ README.md
├─ data/          (raw/, processed/)
├─ notebooks/    (01_exploracion ... 06_pca)
├─ src/          (etl/, preprocessing/, models/)
├─ sql/          (schema.sql, queries.sql)
├─ modelos/      (regresion/, clasificacion/, clustering/)
├─ dashboard/
└─ docs/         (planeacion/, diccionario_datos/, analisis/, modelos/, resultados/)
```

El proyecto conservará la relación entre **datos, código, modelos, resultados y documentación**, para que otra persona pueda comprender lo realizado y, en lo posible, reproducir el análisis.

Referencias bibliográficas

Aguín, J. M. A. (2020, October 13). *Aclarando conceptos: Inteligencia Artificial, Machine Learning, Deep Learning, Big Data y Ciencia de Datos*. campusMVP.es. <https://www.campusmvp.es/recursos/post/aclarando-conceptos-inteligencia-artificial-machine-learning-deep-learning-big-data-y-ciencia-de-datos.aspx>

Cabana, E., & Cabana, E. (2020, October 5). *Inteligencia Artificial, Machine Learning, Deep Learning y Big Data*. Aprende Con Eli. <https://aprendeconeli.com/inteligencia-artificial-machine-learning-deep-learning-y-big-data/>

Machine learning y big data: qué son y cómo funcionan. (2022, February 17). <https://www.beetrack.com/es/blog/machine-learning-y-big-data>

BSG Institute. (2024, November 27). *Machine Learning y Data Mining*. BSG Institute. <https://bsginstitute.com/bs-campus/white-paper/Machine-Learning-y-Data-Mining-1208>

De La Iglesia, E. D. (2026, March 16). *Data Mining vs Big Data diferencias clave*. Big Data International Campus. <https://www.campusbigdata.com/blog/data-mining-vs-big-data/>

BSG Institute. (2024, December 17). *Metodología CRISP-DM: Guía para Científicos de Datos*. BSG Institute. <https://bsginstitute.com/bs-campus/blog/Metodolog%C3%ADa-CRISP-DM-Gu%C3%ADa-para-Cient%C3%ADficos-de-Datos-0>

G, I. R., & G, I. R. (2025, February 21). *CRISP-DM, Metodología de Datos*. iPMOGuide. <https://ipmoguide.com/crisp-dm-metodologia-de-datos/>